

10 de agosto de 2026 - Agosto: Mês do Data Science

1) Fundamentos e Organizações Orientadas a Dados



Carlos Eduardo Pereira

Consultor e profissional de Dados e Inteligência Artificial há 16 anos de experiência em grandes empresas (Bancos e Telecom). Doutorando na linha de Inteligência Artificial, Mestre na linha de Inteligência de Negócios, MBA em Inteligência Artificial e Engenharia de BOTs. Instrutor de Inteligência Artificial Generativa, com especialização em Agentes Inteligentes, Gestor Acadêmico e Professor Universitário para temas de Inteligência Artificial, Negócios e Projetos. Membro do Comitê da Associação Brasileira de Inteligência Artificial. Membro da NVIDIA *Developer Program*.



LinkedIn:



Curadoria de Assuntos nas Lives

Assuntos	Data da Live
Engenharia de Prompts	10/12/2025
Prompts Agenticos	15/12/2025
Onboarding + Dicas Prompts	06/01/2026
Onboarding + Agentes de IA	12/01/2026
Onboarding + Dicas de IA	19/01/2026
IA Aplicada na Carreira	26/01/2026
Onboarding + Geração de Artefatos	03/02/2026
Sistema de Produtividade – Parte 1	09/02/2026
Onboarding + “Como utilizar a Plataforma”	19/02/2026
Sistema de Produtividade – Parte 2	23/02/2026
Onboarding + Sistema de Produtividade – Parte 3	02/03/2026
IA para Pesquisa (Parte 1)	09/03/2026
Onboarding + Correlação de variáveis	23/03/2026

Assuntos	Data da Live
IA para Pesquisa (Parte 2)	30/03/2026
Onboarding + Cases usando o MyHUB.IA	06/04/2026
Soluções de IA na Saúde	08/04/2026
Onboarding + Explicando LLMs	13/04/2026
Soluções de IA para Agronegócios	24/04/2026
Especial Geração de Imagens e Vídeos para uso Corporativo	04/05/2026
Prompting & Coding AI Multi-Agents Systems	11/05/2026
Onboarding + AI Guardrails / AI Harness	18/05/2026
Apresentação Projeto Vencedor ação de aniversário MyHUB.IA	25/05/2026
Soluções de IA: Indústria e Manufatura	01/06/2026
Modelos Open Source e Benchmark de Modelos	03/06/2026
Onboarding + GitHub	15/06/2026
Engenharia de Prompts para geração de Texto e Código	22/06/2026
Engenharia de Prompts para geração de Imagem e Vídeo	29/06/2026
Aprenda a criar seus próprios agentes de IA	21/07/2026
Guia prático: LGPD e uso responsável IA Generativa	27/07/2026
Guia de Modelos de IA + Dicas sobre a Plataforma	03/08/2026
Especial Mês do Data Science – Aula 01: Fundamentos	07/08/2026

Vem por aí!

Agosto: Mês do Data Science

10/08 – Fundamentos e Organizações Orientadas a Dados

Por que dados viraram o ativo mais valioso do séc XXI e o que isso muda na minha organização?

17/08 – Estatística Aplicada e Analytics Descritivo

Como transformar dados brutos em informação confiável e onde guardar esses dados?

24/08 – Analytics Preditivo

Como usar dados históricos para prever comportamentos futuros e segmentar clientes?

31/08 – Visualização de Dados + Dashboards

Como construir, comunicar, distribuir e governar tudo que fazemos com os dados?

PERGUNTA ESTRATÉGICA

Por que dados viraram o ativo mais valioso do século XXI e o que isso muda para a minha organização?

Objetivos de aprendizagem

- Compreender a evolução do BI tradicional ao Analytics moderno
- Dominar os 5 V's do Big Data e sua implicação estratégica
- Diferenciar os 4 tipos de analytics (descritivo, diagnóstico, preditivo, prescritivo)
- Identificar os 6 pilares de dados e tecnologia nas organizações
- Reconhecer o que caracteriza uma organização data-driven

Decisão orientada por dados

Fruto de décadas de evolução tecnológica e organizacional que começou muito antes da internet

1960–1970	Management Information Systems (MIS) : primeiros sistemas de informação gerencial. Foco em relatórios (o que já aconteceu).	2010	Business Analytics : foco na predição com modelos estatísticos e Machine Learning. Big Data com dados estruturados e não estruturados (Python, R, Spark).
1980	Decision Support Systems (DSS) : início do uso de modelos quantitativos para decisão. Início das análises preditivas (ainda incipiente).	2020	Empresas Data Driven + IA : uso de IA Generativa (além da preditiva), cultura orientada a dados, decisões automatizadas.
1990	Data Warehouses e OLAP : repositórios de dados + análises multidimensionais. Início dos dashboards, expandindo para diversos setores.	2025/26	Empresas Agênticas / AI Driven Solopreneurs.
2000	BI Tradicional e maior capacitação das equipes (olhar para o agora). Ferramentas como Cognos, MicroStrategy etc.		

O que evoluiu foi a forma de como fazíamos

Olhar para o passado

Relatórios
possibilitados via
internet + ERP

Olhar para o presente

Bancos de Dados +
Dashboards e
ferramentas de BI

Olhar para o futuro

Big Data + Machine
Learning

Olhar da “Otimização e generatividade”

Inclusive das decisões

Davenport descreve essa trajetória como **Analytics 4.0**: as decisões orientadas por dados devem ser tratadas como alavancas estratégicas, não como custos de TI.

Em qual estágio está a empresa que você trabalha?

Vamos dar um salto temporal e irmos para o Data Science

Comumente confundido com “Big Data” e pode levar a decisões erradas.

A eficiência do Big Data passa por “3 Vs” (MIS Quarterly, 2012):

Volume

Relacionado ao aumento na **escala dos dados** — de GB para TB, PB e ZB.

- O mundo gerou mais de 180 zetabytes em 2025 (Forbes)
- 1 celular moderno tem cerca de 256 GB
- 700 bilhões de celulares cheios

Velocidade

Rapidez de geração e processamento — de batch (passado) para **real-time (presente)**.

- Encurta a janela de decisão consideravelmente (de carta para e-mail/WhatsApp)
- Ex.: análise de fraudes no cartão de crédito

Variedade

Diversidade dos dados e formatos — de estruturados (bases de dados, ERPs) para não estruturados.

>80% dos dados do mundo são **não estruturados** (textos, imagens, vídeos, áudios, logs). Ex.: avaliações do iFood (texto) e fotos dos pratos (imagem).

A partir de 2022, mais 2 Vs (Chen, 2022)

Veracidade

Qualidade e confiabilidade dos dados.

Dados imprecisos ou incompletos destroem qualquer análise — "garbage in, garbage out".

Valor

Capacidade de gerar resultado.

Dados sem valor gerado se torna custo, não um ativo estratégico — ex.: modelo de recomendação que recomenda mal.

Importância em avaliar o que está sendo feito com os dados.

Momento para refletirmos

Antes de investir em plataformas ou tecnologias de dados, pergunte:

Qual "V" é o gargalo da minha organização?

Se a resposta for "veracidade", mais "volume" só aumentará os problemas.

Se a resposta for "valor", o problema provavelmente não é técnico, mas estratégico: você ainda não sabe quais perguntas fazer aos dados.

Para discutirmos: alguém conhece ou já passou por isso na carreira?

Não precisa falar o nome da empresa se não quiser...

Os quatro tipos de Analytics

Essencial saber a distinção **entre os quatro tipos**, pois cada um responde a uma pergunta diferente e agrega um nível diferente de valor estratégico

Descritivo

PERGUNTA CENTRAL
O que aconteceu?

O QUE FAZ

Sumariza dados históricos, relatórios, KPIs, dashboards. É o ponto de partida para toda análise.

Diagnóstico

PERGUNTA CENTRAL
Por que aconteceu?

O QUE FAZ

Explora causas e correlações, drill-down, análise de segmentos, decomposição de variância.

Preditivo

PERGUNTA CENTRAL
O que vai acontecer?

O QUE FAZ

Modelos estatísticos e de Machine Learning para prever comportamentos futuros com base em padrões históricos.

Prescritivo

PERGUNTA CENTRAL
O que devo fazer?

O QUE FAZ

Otimização e recomendações de ações. Combina modelos preditivos com regras de negócio e simulações.

EVOLUÇÃO E DIFUSÃO DOS ANALYTICS NAS ORGANIZAÇÕES

Da visualização do passado à automação inteligente das ações futuras



TENDÊNCIA DE MERCADO: cada vez mais difundido e acessível com IA, agentes e automação



★ A evolução do analytics representa a evolução da própria tomada de decisão nas organizações: da visualização do passado para a automação inteligente das ações futuras.

VAMOS FAZER JUNTOS

Cenário 1

Um banco digital percebe que muitos clientes cancelam a conta poucos dias após:

- redução do limite;
- aumento de juros;
- contato com suporte.

⚠ O problema: quando o banco percebe o cancelamento, o cliente já foi embora.

Qual tipo de implementação de analytics vocês recomendam? (descritivo, diagnóstico, preditivo ou prescritivo)

VAMOS FAZER JUNTOS

Cenário 1 – Resolução

A empresa já entende o **que** aconteceu e algumas causas.

Agora ela quer antecipar o risco e agir antes da perda.

SOLUÇÃO ESPERADA

Modelo de churn · score de risco · previsão de cancelamento ·
alertas preventivos · probabilidade de evasão

PEGADINHA CONCEITUAL

Alguns grupos podem ir direto para a campanha automática. Mas antes disso: *"a empresa precisa saber QUEM provavelmente vai cancelar."*

Tipo esperado: ☒ Preditivo

VAMOS FAZER JUNTOS

Cenário 2

Uma rede de academias percebeu queda de receita nos últimos 5 meses, mas os gestores regionais insistem que "as unidades estão cheias".

A diretoria possui: sistema de acesso por catraca; ERP financeiro; dados de planos; app de treinos.

⚠ O problema: cada área apresenta números diferentes nas reuniões.

Qual tipo de implementação de analytics vocês recomendam? (descritivo, diagnóstico, preditivo ou prescritivo)

VAMOS FAZER JUNTOS

Cenário 2 – Resolução

O problema principal **não** é previsão nem IA. A empresa ainda não possui visão única, não possui indicadores consolidados e não possui transparência operacional.

SOLUÇÃO ESPERADA

Dashboard executivo · KPIs padronizados · consolidação de métricas · análise temporal · visão única de receita, frequência e cancelamentos

PEGADINHA CONCEITUAL

Os alunos mais técnicos podem querer prever churn imediatamente. Mas o gargalo real é: *"a empresa ainda não consegue enxergar claramente o que está acontecendo."*

Tipo esperado: ☒ Descritivo

VAMOS FAZER JUNTOS

Cenário 3

Uma empresa de delivery percebe que o NPS caiu drasticamente em duas capitais.

A diretoria possui: tempo médio de entrega não aumentou; preço permaneceu estável; número de pedidos cresceu.

⚠ O problema: os executivos não conseguem explicar a piora da experiência.

Qual tipo de implementação de analytics vocês recomendam? (descritivo, diagnóstico, preditivo ou prescritivo)

VAMOS FAZER JUNTOS

Cenário 3 – Resolução

Aqui já existe monitoramento. O problema agora é investigar relações, cruzar variáveis e encontrar a causa raiz.

SOLUÇÃO ESPERADA

Análise segmentada · correlações · cohort/funnel · análise por bairros/restaurantes/horários · cruzamento entre SAC, logística e avaliações

PEGADINHA CONCEITUAL

Alguns grupos vão sugerir IA preditiva. Mas o gargalo real é: *"por que o problema está acontecendo."*

Tipo esperado: ☒ Diagnóstico

VAMOS FAZER JUNTOS

Cenário 4

Uma grande operação de e-commerce possui milhares de pedidos por hora, centros de distribuição em várias regiões, múltiplas transportadoras e custos logísticos variando em tempo real.

Os analistas definem: priorização; roteamento; distribuição de estoque; transportadora ideal.

⚠ O problema: as decisões humanas não conseguem acompanhar a velocidade da operação.

Qual tipo de implementação de analytics vocês recomendam? (descritivo, diagnóstico, preditivo ou prescritivo)

VAMOS FAZER JUNTOS

Cenário 4 – Resolução

Aqui o desafio não é mais entender ou prever. O desafio é recomendar, otimizar e automatizar a decisão.

SOLUÇÃO ESPERADA

Motor de decisão · recomendação automática · otimização logística
· IA operacional · sistema autônomo de roteamento

PEGADINHA CONCEITUAL

Muitos grupos vão parar no preditivo: "prever demanda". Mas o gargalo real é: *"definir automaticamente a melhor ação possível em tempo real."*

Tipo esperado: ☒ Prescritivo

Os seis pilares de dados e tecnologia

As organizações verdadeiramente Data Driven não constroem apenas ferramentas, mas uma arquitetura sistêmica em toda a organização.

Essa arquitetura é conhecida como pilares para Dados e Tecnologia:

Qualidade dos Dados

Governança dos Dados

Ferramentas de Dados

Integração de Sistemas

Segurança da Informação

Capacidade Computacional

OS 6 PILARES DE DADOS E TECNOLOGIA

MÓDULOS INDEPENDENTES, RETROALIMENTADOS E INTERDEPENDENTES



INTERDEPENDÊNCIA DOS PILARES



A fragilidade de qualquer um compromete todos os outros.

“

Por que dados viraram o ativo mais valioso do século XXI e o que isso muda para a minha organização?

Vamos fazer uma análise prática!

Fundação estatística: o que são dados?

CONCEITOS FUNDAMENTAIS

1 Datasets (conjunto de dados)

Coleção organizada de dados sobre um conjunto de entidades — é a **matéria-prima de toda análise.**

2 Observação (linhas)

Registro individual dentro de um dataset. *Exemplo:* um cliente, uma transação, um produto etc.

3 Variável (coluna)

Uma característica mensurada para cada observação. *Exemplo:* idade do cliente, valor da compra, categoria do produto etc.

Tipos de variáveis

A classificação correta determina quais técnicas analíticas são mais aplicáveis

Tipo	Subtipo	Definição	Exemplos
Qualitativa (categórica)	Nominal	Categorias sem ordem natural entre si	Gênero, estado, cor, categoria de produto
	Ordinal	Categorias com ordem natural, mas sem distância mensurável	Escolaridade (fundamental < médio < superior), NPS (0-10), Rating de estrelas no app
Quantitativa (numérica)	Discreta	Valores inteiros contáveis	Número de filhos, quantidade de pedidos, idade em anos
	Contínua	Valores em qualquer ponto de um intervalo real	Renda mensal, peso, temperatura, tempo de entrega

 **Por que isso importa:** a classificação da variável determina qual tratamento estatístico é válido (moda para nominal, média para contínua) e qual modelo de Machine Learning se aplica (classificação para categórica, regressão para contínua).

Segmentação estratégica de clientes

VAMOS FAZER JUNTOS

Trabalhamos na área de Analytics de um Grupo de Shopping Centers e fomos notificados que as abordagens de Marketing não estão gerando resultados (baixa eficiência em campanhas).

Como identificar padrões de comportamento ocultos que permitam agrupar os clientes além da simples demografia?

O QUE IREMOS ANALISAR

Entender a relação entre "Renda Anual" x "Score de Gastos" (H1: quem ganha mais, gasta mais)

Colab: https://colab.research.google.com/drive/18dLpsycDwHpBRNZah2-7xkSynMBL4Hp3?usp=drive_link

“

Por que dados viraram o ativo mais valioso do século XXI e o que isso muda para a minha organização?

Case do iFood

A maior plataforma de delivery da América Latina

O QUE O IFOOD FAZ?

- Conecta consumidores, restaurantes e entregadores numa só plataforma
- Opera em +1.200 cidades no Brasil, México e Colômbia
- Representa ~0,5% do PIB brasileiro (2022)
- Usa IA em +100 modelos a cada sessão de usuário
- Infraestrutura: AWS como provedor cloud principal
- Passou de 100 milhões de eventos por dia para 8–10 bilhões



80M

pedidos por mês

80%

market share no Brasil

+330K

parceiros cadastrados

É uma empresa Data Driven?

Análise dos 6 pilares de dados e tecnologia do iFood

Pilar	Maturidade	Destaques	Lacunas
Qualidade de Dados	★★★★☆	Spark Declarative Pipelines; redução de 4.000 para 100 tabelas (-70% manutenção, -67% custo de processamento)	Sem plataforma formal de data observability
Governança	★★★★☆	Área transversal de privacidade; conformidade avançada com LGPD; tokenização financeira; portal de privacidade self-service	Sem evidência de DAMA-DMBOK ou Data Mesh formal
Ferramentas	★★★★★	AWS + Databricks + Confluent; MLOps com ML Go!; +100 modelos de IA por sessão de usuário	Ausência documentada de feature store centralizado
Integração	★★★★☆	Event-driven com AWS EventBridge + Confluent Kafka; 2.000+ microserviços integrados	API para parceiros fragmentada entre versões
Segurança	★★★★☆	Tokenização de cartões; times especializados; conformidade LGPD	Incidente 2021 revelou gaps em controle de acesso de terceiros
Capacidade Computacional	★★★★★	Kubernetes (-40% custo); AWS elástica; SLA de entrega de 80% → 95%; iFood AI Academy	FinOps para ML e edge computing pouco explorados

Demais resultados gerados pelos dados

Área	Indicador	Resultado
Qualidade de Dados	Tabelas no data lake	4.000 → 100 (-97,5%)
Infraestrutura	Custo de processamento	Redução de 67%
Logística (ML)	SLA de entrega no prazo	80% → 95%
Logística (ML)	Tempo ocioso de entregadores	Redução de 50%
Logística (ML)	Distância percorrida por entregadores	Redução de 12%
IA / Personalização	Modelos de IA por sessão de usuário	Mais de 100 modelos simultâneos

Perguntas para discutirmos

- 1 Qual dos 6 pilares vocês consideram mais crítico para o estágio atual do iFood?
- 2 O iFood investiu pesadamente em ferramentas e capacidade computacional, mas governança ficou com baixa avaliação. O que isso revela sobre as prioridades típicas de startups em fase de crescimento acelerado?
- 3 Incidentes não são raros no iFood, como troca do nome de restaurantes, e acabam expondo uma fragilidade de segurança. O que poderia ter sido feito?
- 4 Transportando para a organização de vocês, como vocês classificariam a empresa em que trabalham em relação aos 6 pilares?



Notícias | 30/10/2023

Comunicado oficial – Troca de nomes de estabelecimentos no app

Fechando a aula 1

"Por que dados viraram o ativo mais valioso do século XXI e o que isso muda para a minha organização?"

PORQUE DADOS PASSARAM A...

- reduzir incerteza
- acelerar decisões
- personalizar experiências
- automatizar operações
- criar novos modelos de negócio
- escalar Inteligência Artificial

ISSO MUDA PROFUNDAMENTE AS ORGANIZAÇÕES

- decisões deixam de ser apenas intuitivas
- analytics deixa de ser suporte operacional
- dados passam a influenciar estratégia, cultura e vantagem competitiva

Em resumo: organizações que aprendem mais rápido com seus dados tendem a decidir melhor, adaptar-se mais rápido e competir em maior escala.

Na próxima aula

Agosto: Mês do Data Science

10/08 – Fundamentos e Organizações Orientadas a Dados

Por que dados viraram o ativo mais valioso do séc XXI e o que isso muda na minha organização?

17/08 – Estatística Aplicada e Analytics Descritivo

Como transformar dados brutos em informação confiável e onde guardar esses dados?

24/08 – Analytics Preditivo

Como usar dados históricos para prever comportamentos futuros e segmentar clientes?

31/08 – Visualização de Dados + Dashboards

Como construir, comunicar, distribuir e governar tudo que fazemos com os dados?

Muito obrigado!

No caso de dúvidas, a comunidade está aberta, vamos usá-la.

Siga as redes sociais da MyHub.ia

Meu LinkedIn:

